OTUS

Журналы

otus.ru

Проверить, идет ли запись

Меня хорошо видно && слышно?

Ставим “+”, если все хорошо
“-”, если есть проблемы

Тема вебинара

Журналы

Ведущий разработчик PostgreSQL/Greenplum в Сбере

Специалист в области разработки и проектирования витрин данных в PostgreSQL/Greenplum, а также в области разработки хранимых процедур в таких СУБД как PostgreSQL/Greenplum, Oracle, MS SQL Server.

Правила вебинара

Активно
участвуем

Off-topic обсуждаем
в учебной группе ТГ

Задаем вопрос
в чат или голосом

Вопросы вижу в чате,
могу ответить не сразу

Маршрут вебинара

1. Буферный кэш
2. Журнал предзаписи WAL
3. Контрольная точка
4. Настройки журнала

Цели вебинара

К концу занятия вы сможете

1. Настраивать журналирование;
2. Корректно настроить схемы контрольных точек;

Смысл

Зачем вам это уметь

1. Обеспечить высокую надежность;
2. Обеспечить оптимальную производительность;

Буферный кэш

Буферный кэш

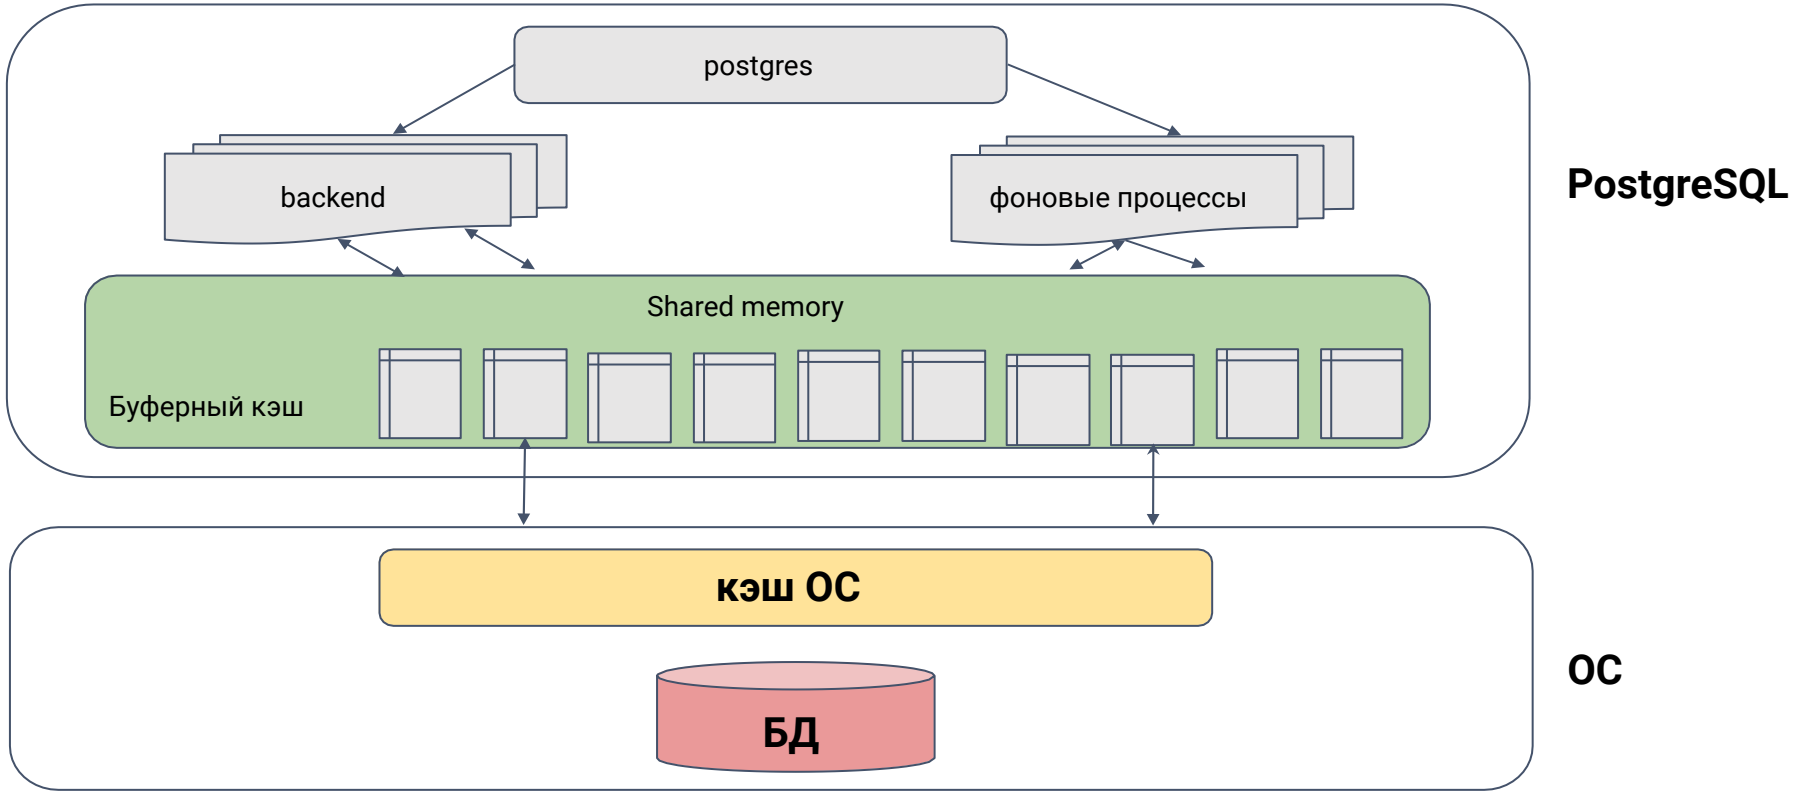

Буферный кэш. Зачем?

Ускоряем работу всей системы.

- Оперативная память очень быстра, но ее мало;
- HDD огромный, но медленный.

Буферный кэш. Состав

Каждый буфер состоит из одной страницы данных и заголовка. Размер по умолчанию 8 кб. Заголовок содержит:

- расположение страницы на диске (файл и номер страницы в нем);
- число обращений к буферу (счетчик увеличивается каждый раз, когда процесс читает или изменяет буфер, максимально значение 5);
- признак того, что данные на странице изменились и рано или поздно должны быть записаны на диск (грязный буфер).

Изначально кэш содержит:

- пустые буферы, и все они связаны в список свободных буферов;
- указатель на «следующую жертву» при вытеснении старых буферов;
- также используется хеш-таблица, чтобы быстро находить нужную страницу в кэше.

Размер буферного кэша задается параметром **shared_buffers**. Его изменение **требует перезапуска** сервера.

Буферный кэш. Механизм работы

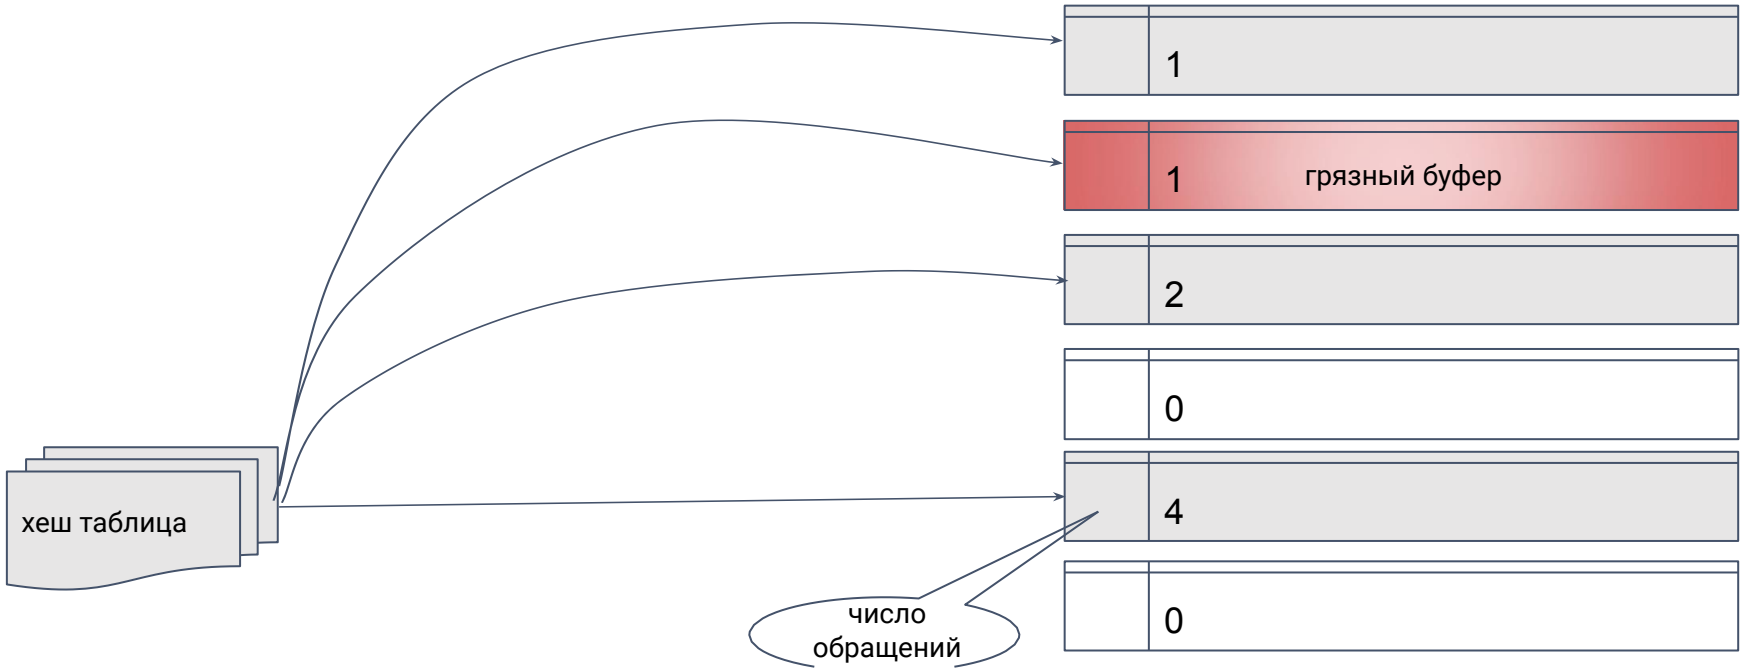

Буферный кэш. Механизм работы

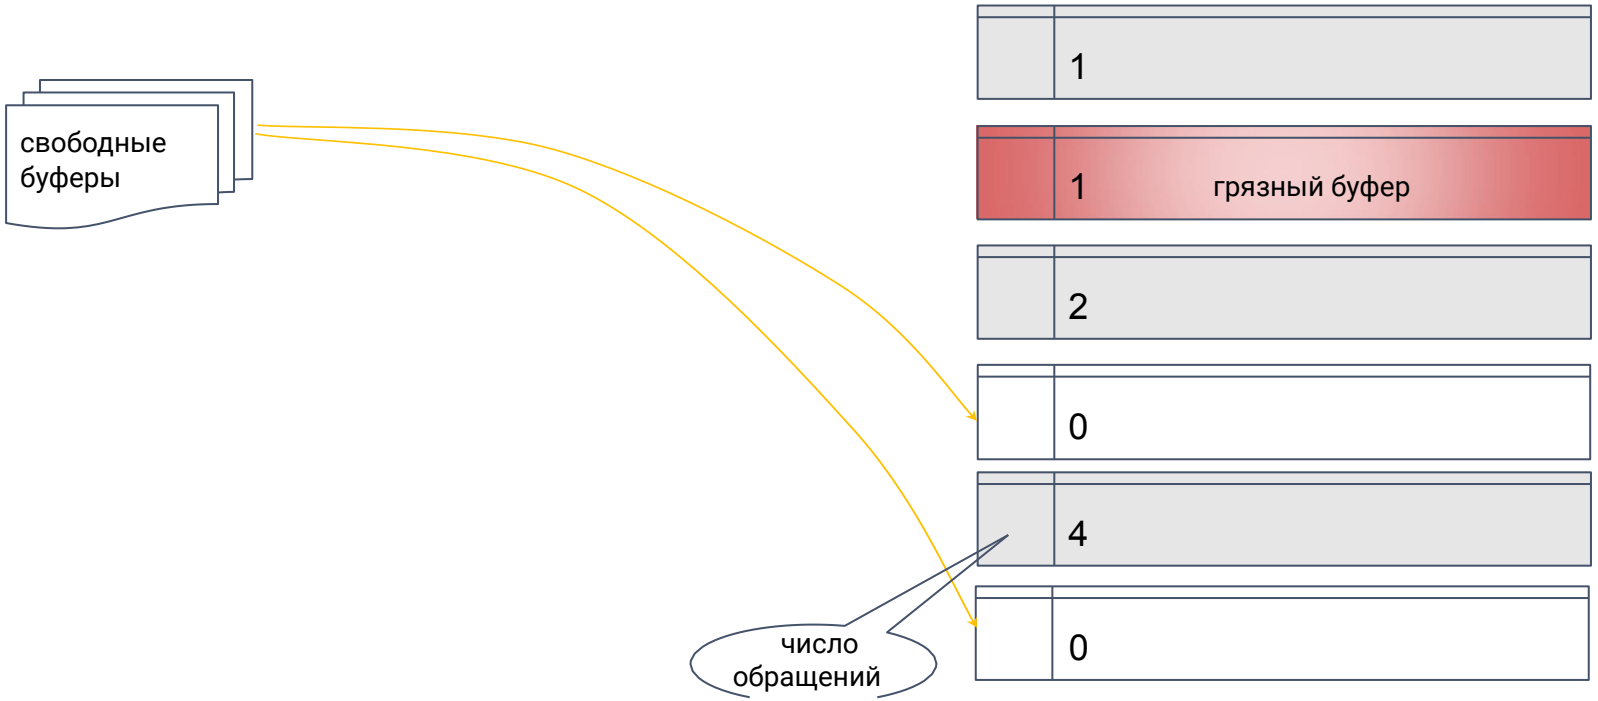

Буферный кэш. Механизм работы

Сначала ищем в буферном кэше по хешу. Если нужная страница найдена в кэше, процесс должен «закрепить» буфер (увеличить счетчик pin count) и увеличить число обращений(счетчик usage count).

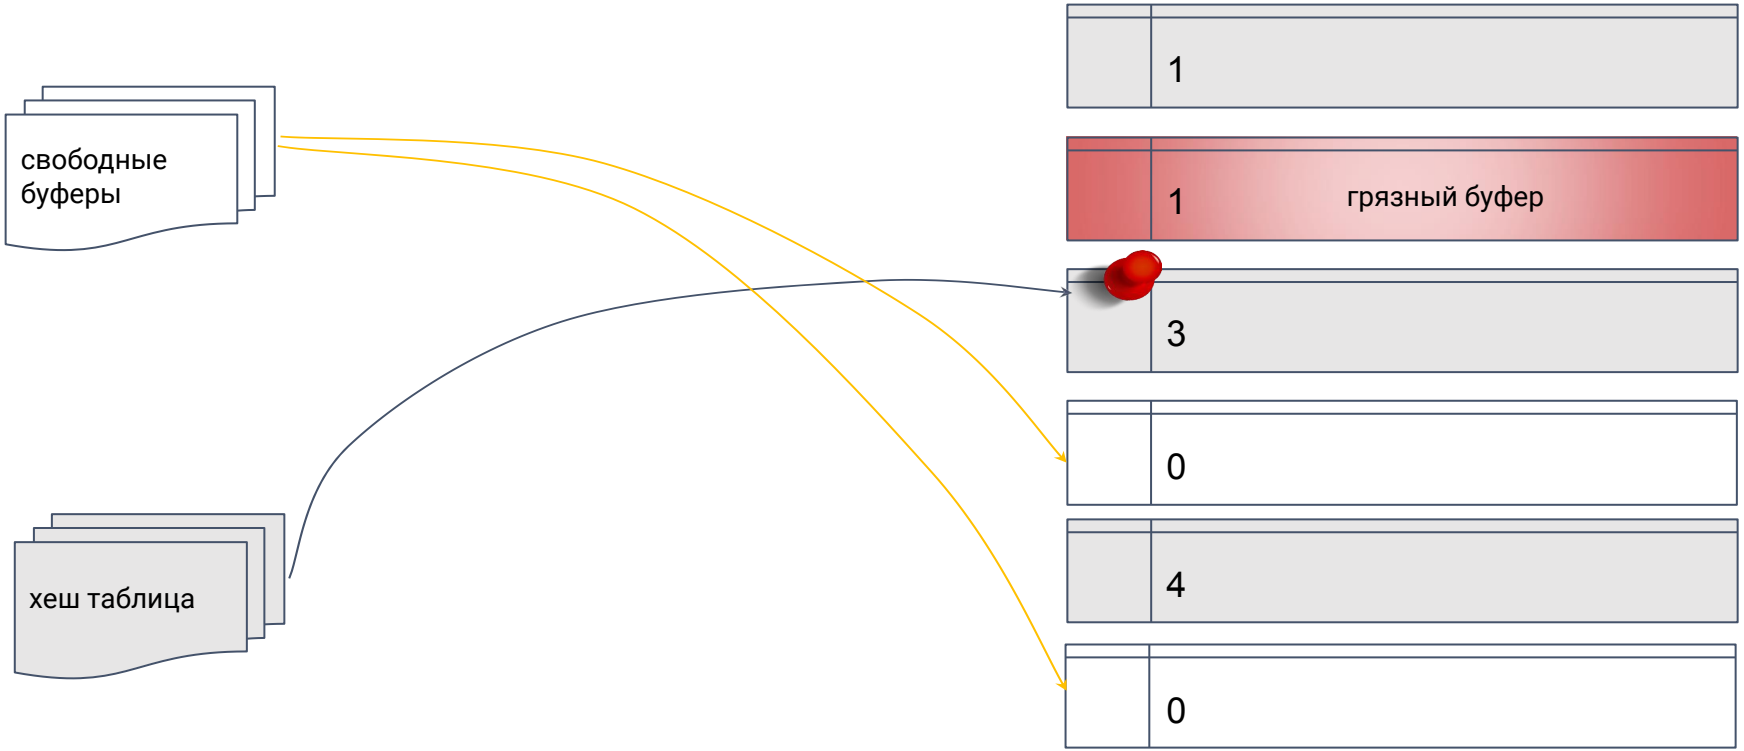

Буферный кэш. Механизм работы

Если нет страницы в кэше, то грузим с диска в первый пустой блок и добавляем строку в хеш таблицу.

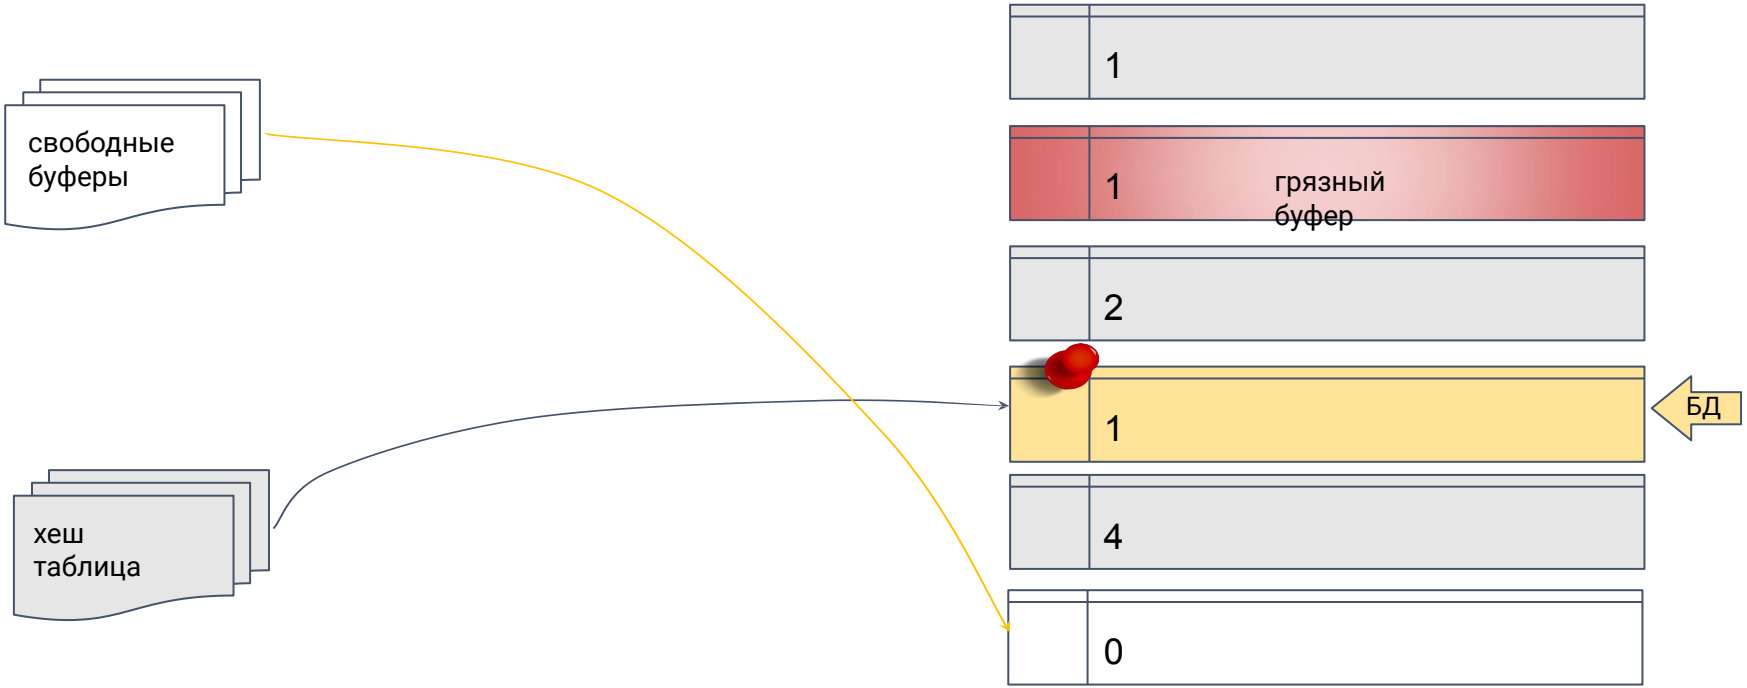

Буферный кэш. Чтение с вытеснением

В какой-то момент все свободные блоки заканчиваются. Что делать дальше?

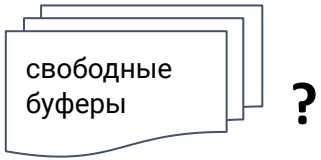

?

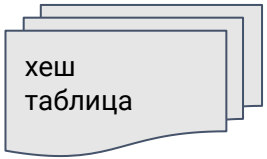

?

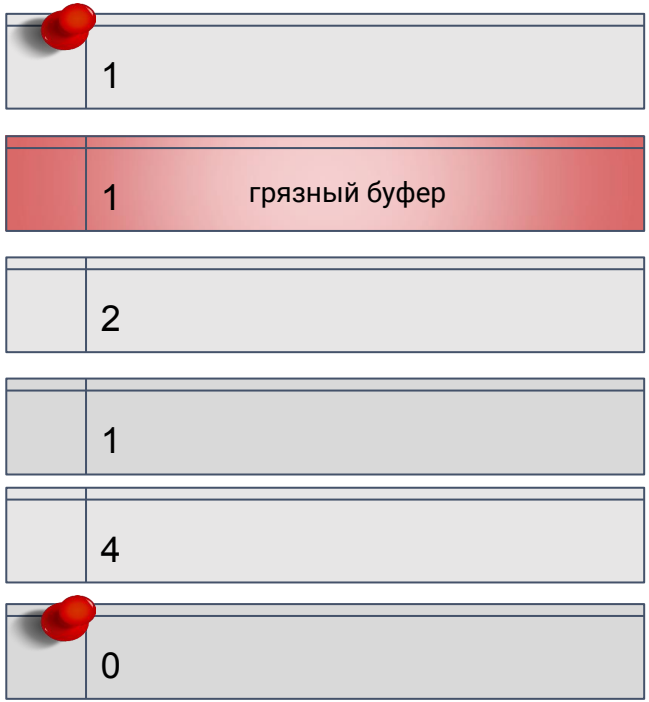

Буферный кэш. Чтение с вытеснением

В какой-то момент все свободные блоки заканчиваются. Что делать дальше?

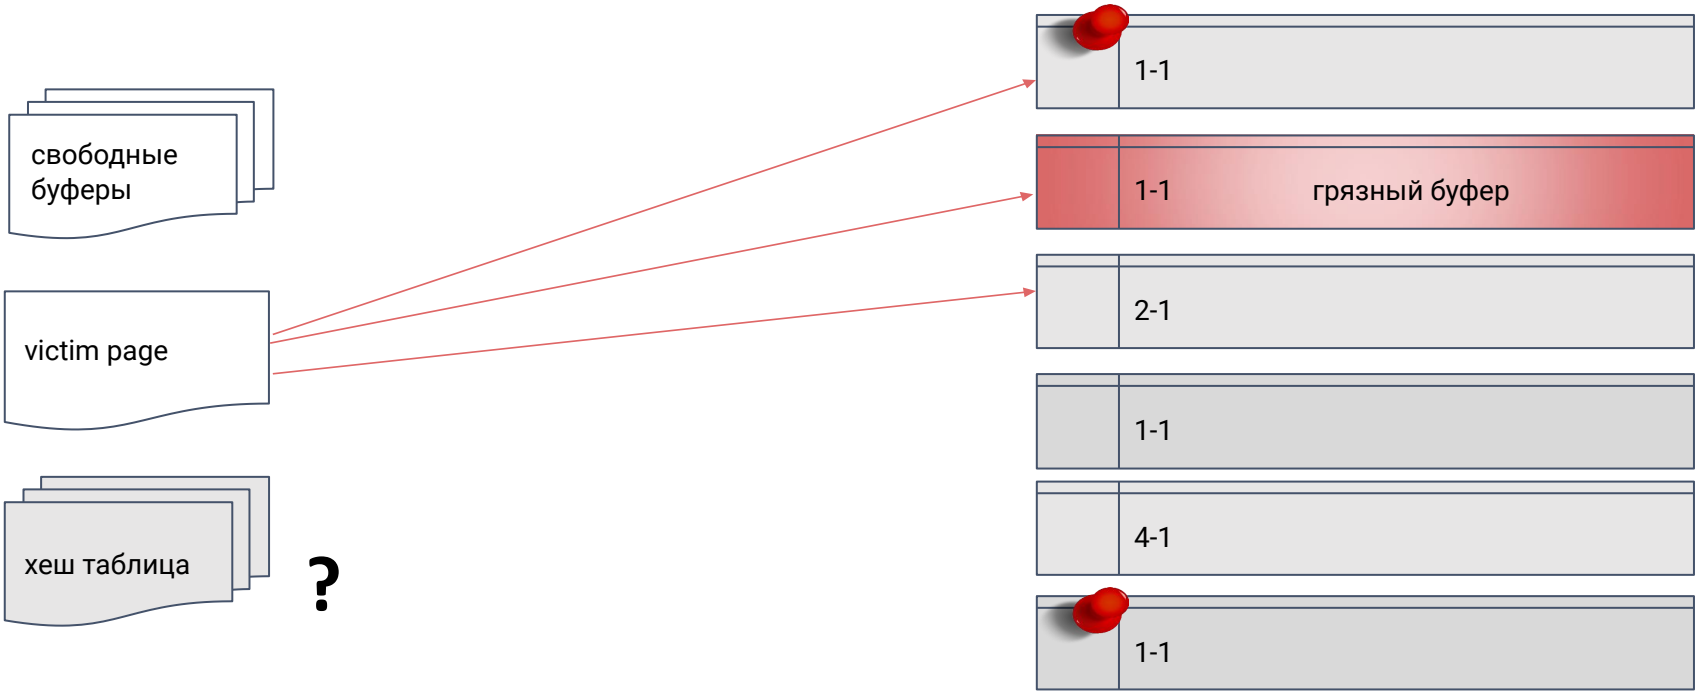

Буферный кэш. Чтение с вытеснением

Грязную страницу нужно **заменить, но для этого ее нужно сбросить на диск.** Частично сглаживается процессом **bgwriter** и механизмом контрольных точек.

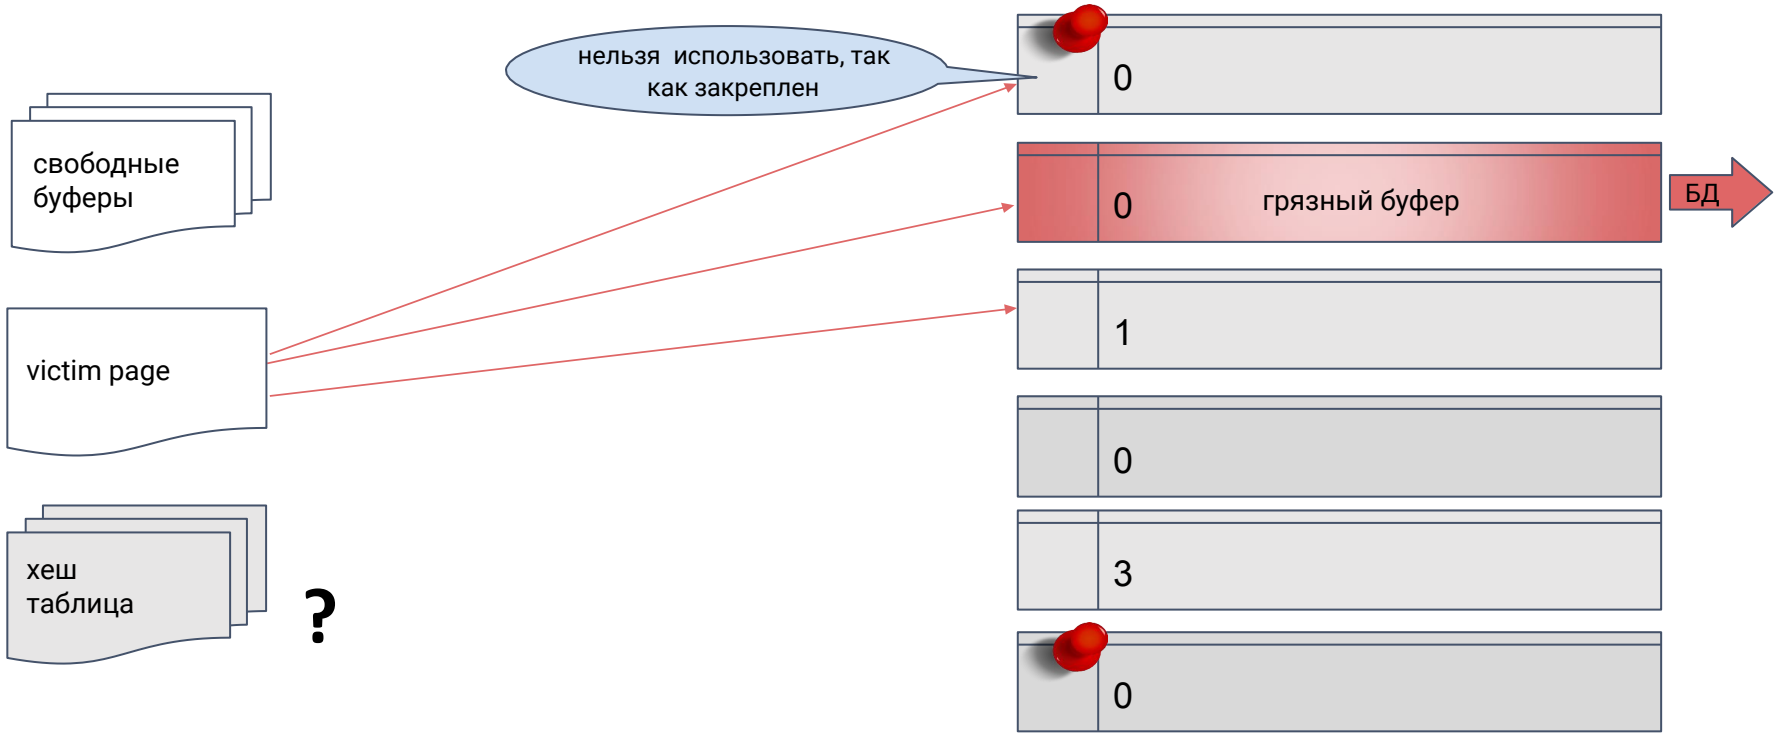

Буферный кэш. Чтение с вытеснением

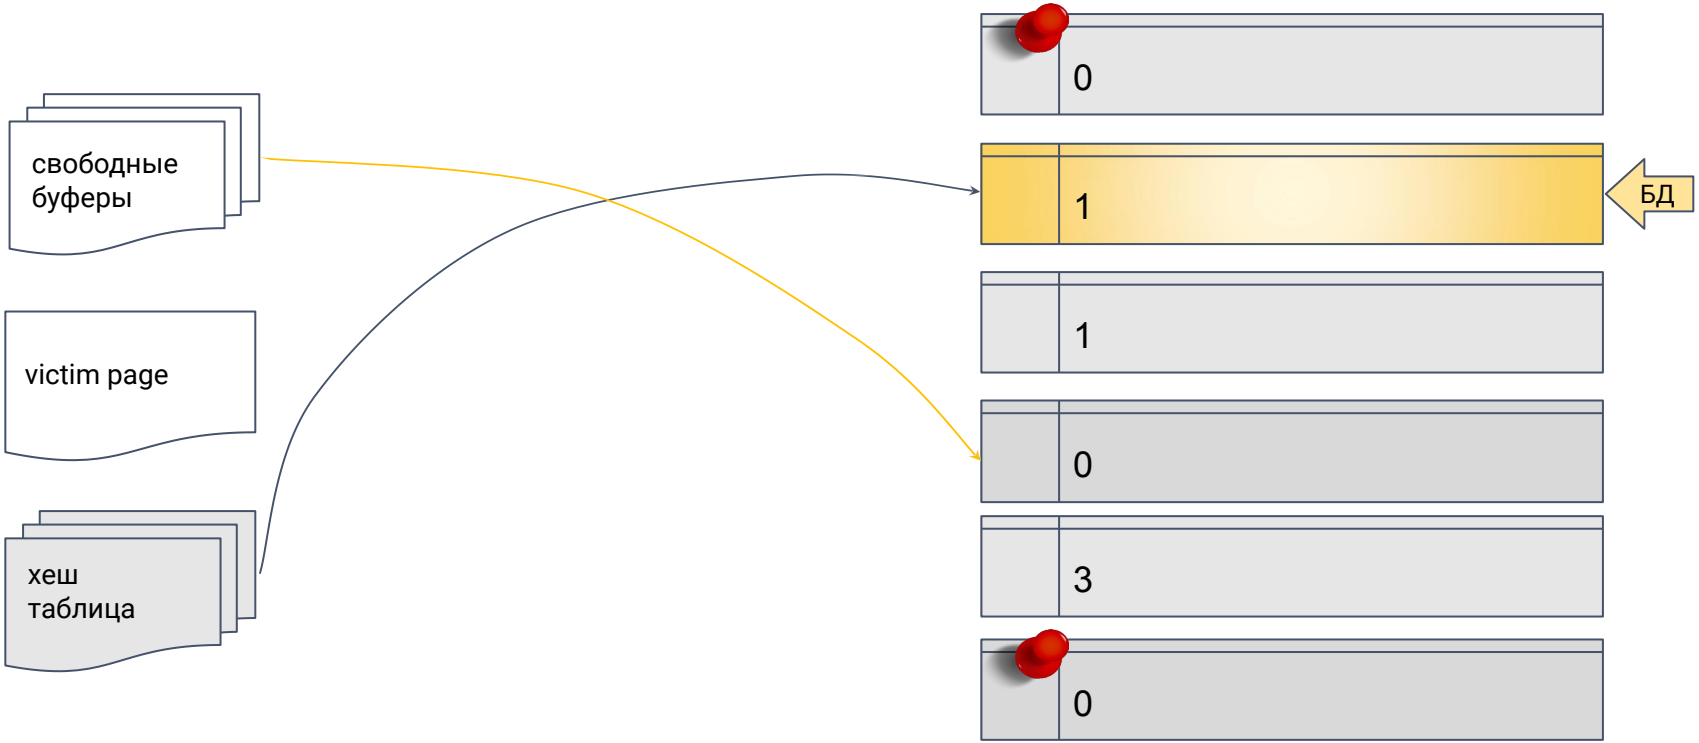

Буферный кэш. Массовое вытеснение

Буферное кольцо

Часть буферного кэша, выделенная для одной операции предотвращает вытеснение кэша «одноразовыми» данными.

операция	кол-во страниц	грязные буферы
последовательное чтение (несколько операций одновременно)	32	исключаются из кольца
очистка (VACUUM)	32	вытесняются на диск
массовая запись (COPY, CTAS)	≤2048	вытесняются на диск

Буферный кэш. Настройка

По умолчанию **shared_buffers = 128MB**

Буферный кэш должен содержать «активные» данные:

- при меньшем размере постоянно вытесняются полезные страницы;
- при большем размере бессмысленно растут накладные расходы.

Начальная рекомендация — **25**% ОЗУ

Нужно учитывать двойное кэширование - если страницы нет в кэше СУБД, она может оказаться в кэше ОС, но алгоритм вытеснения ОС не учитывает специфики базы данных.

Буферный кэш. Временные таблицы

Данные временных таблиц:

- видны только одному сеансу — нет смысла использовать общий кэш;
- существуют в пределах сеанса — не жалко потерять при сбое.

Используется локальный буферный кэш:

- не требуются блокировки;
- память выделяется по необходимости в пределах temp_buffers;
- обычный алгоритм вытеснения.

Буферный кэш. Разогрев кэша

- **pg_prewarm**
- используется после рестарта кластера
- заполняет кэш указанными таблицами

Вопросы?

Журнал предзаписи

Буферный кэш && WAL

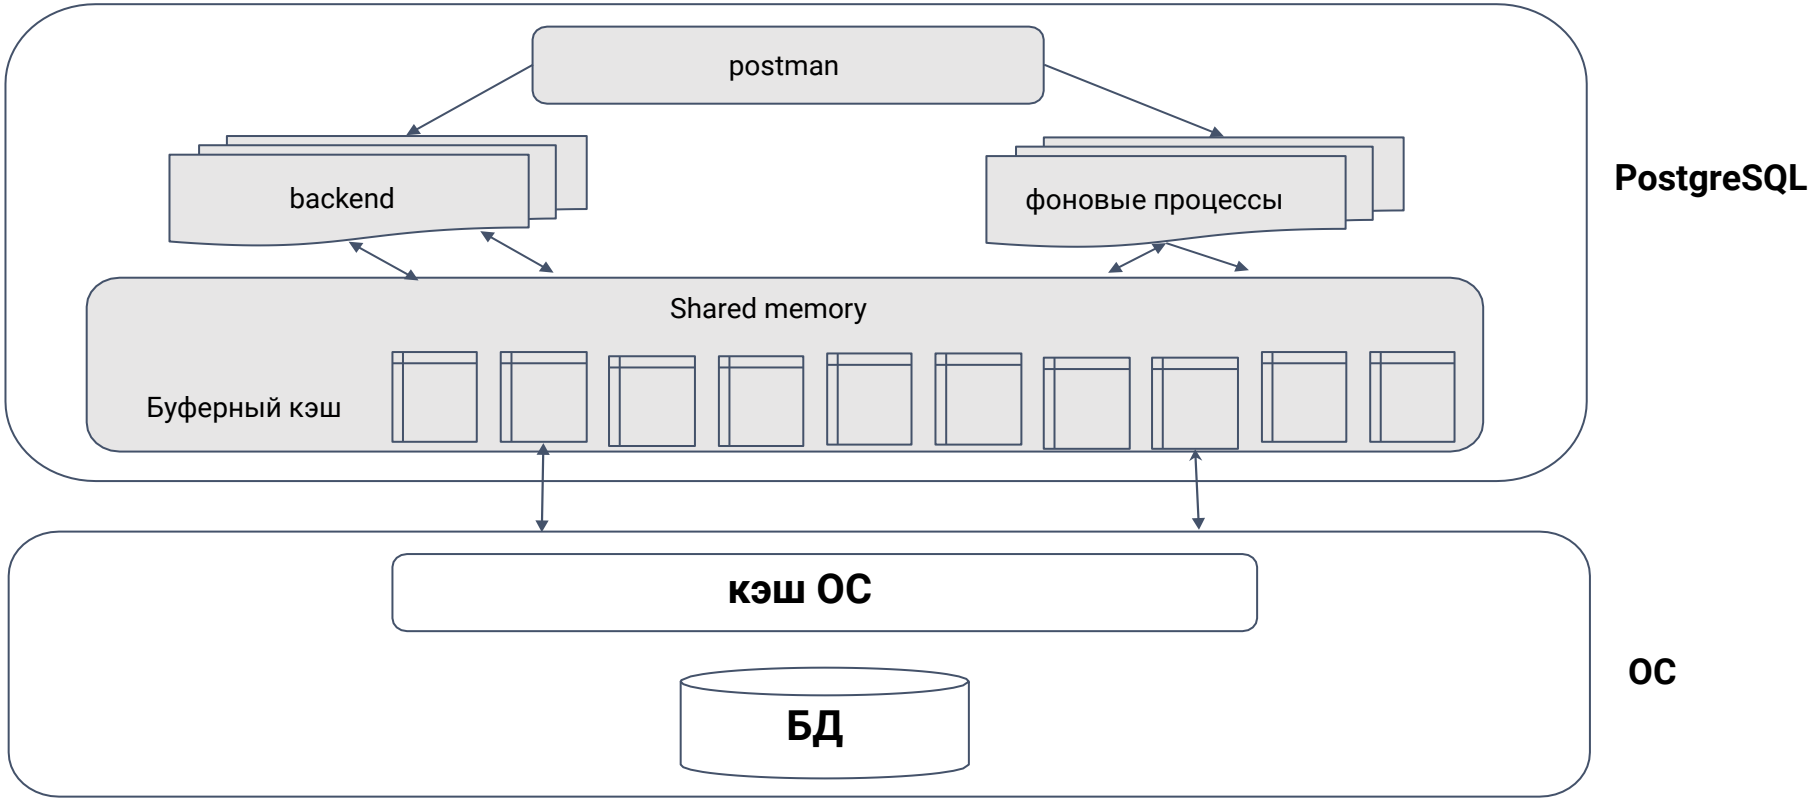

Write ahead log - WAL

Основная задача

- возможность восстановления согласованности данных после сбоя

Механизм

- при изменении данных действие также записывается в журнал журнальная запись попадает на диск раньше измененных данных
- восстановление после сбоя — повторное выполнение потерянных операций с помощью журнальных записей

Что туда попадает

- изменение любых страниц в буферном кэше
- фиксация и отмена транзакций - буферы XACT
- НЕ ПОПАДАЮТ - временные и нежурналируемые таблицы

WAL. Устройство

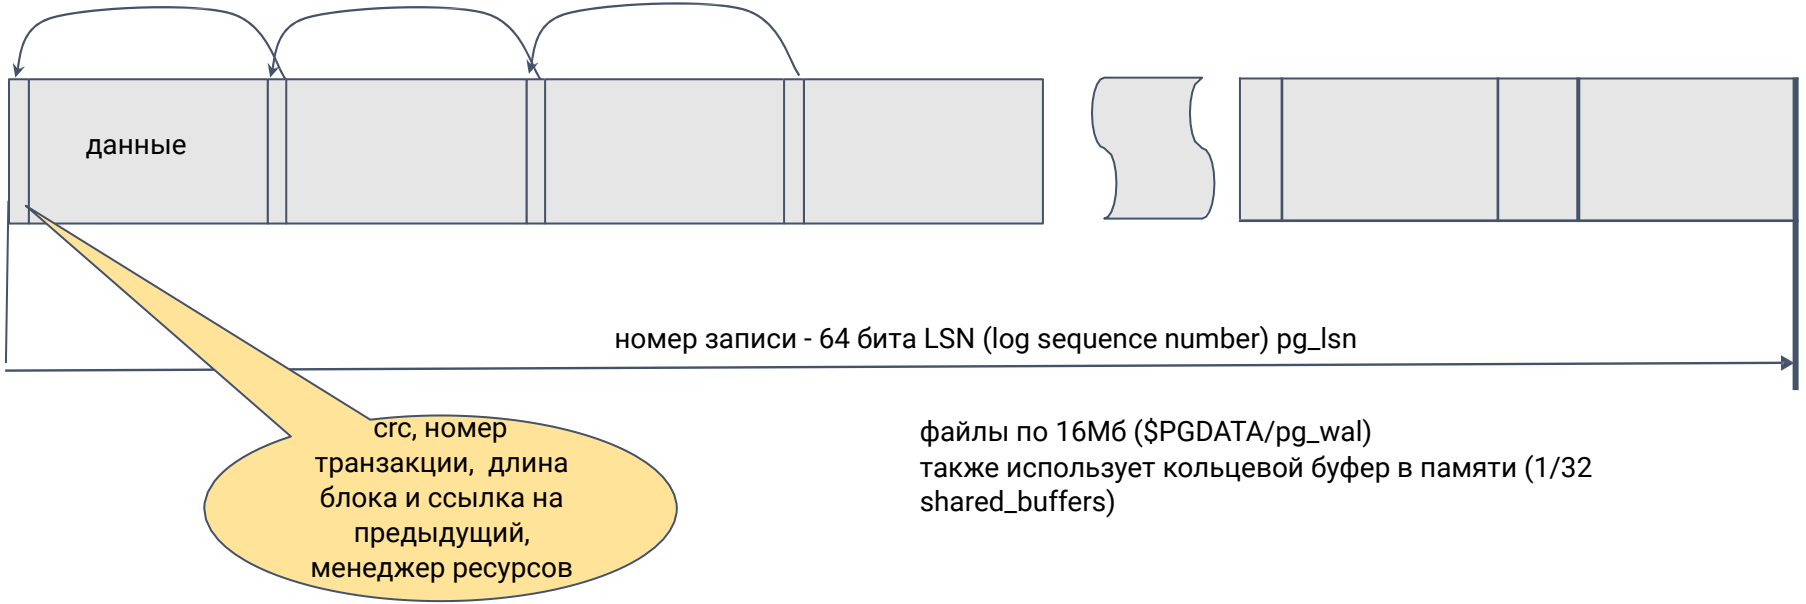

файлы по 16Мб ($PGDATA/pg_wal)
также использует кольцевой буфер в памяти (1/32 shared_buffers)

$/usr/lib/postgresql/13/bin/pg_waldump -r list - список менеджеров

WAL. Механизм упреждающей записи

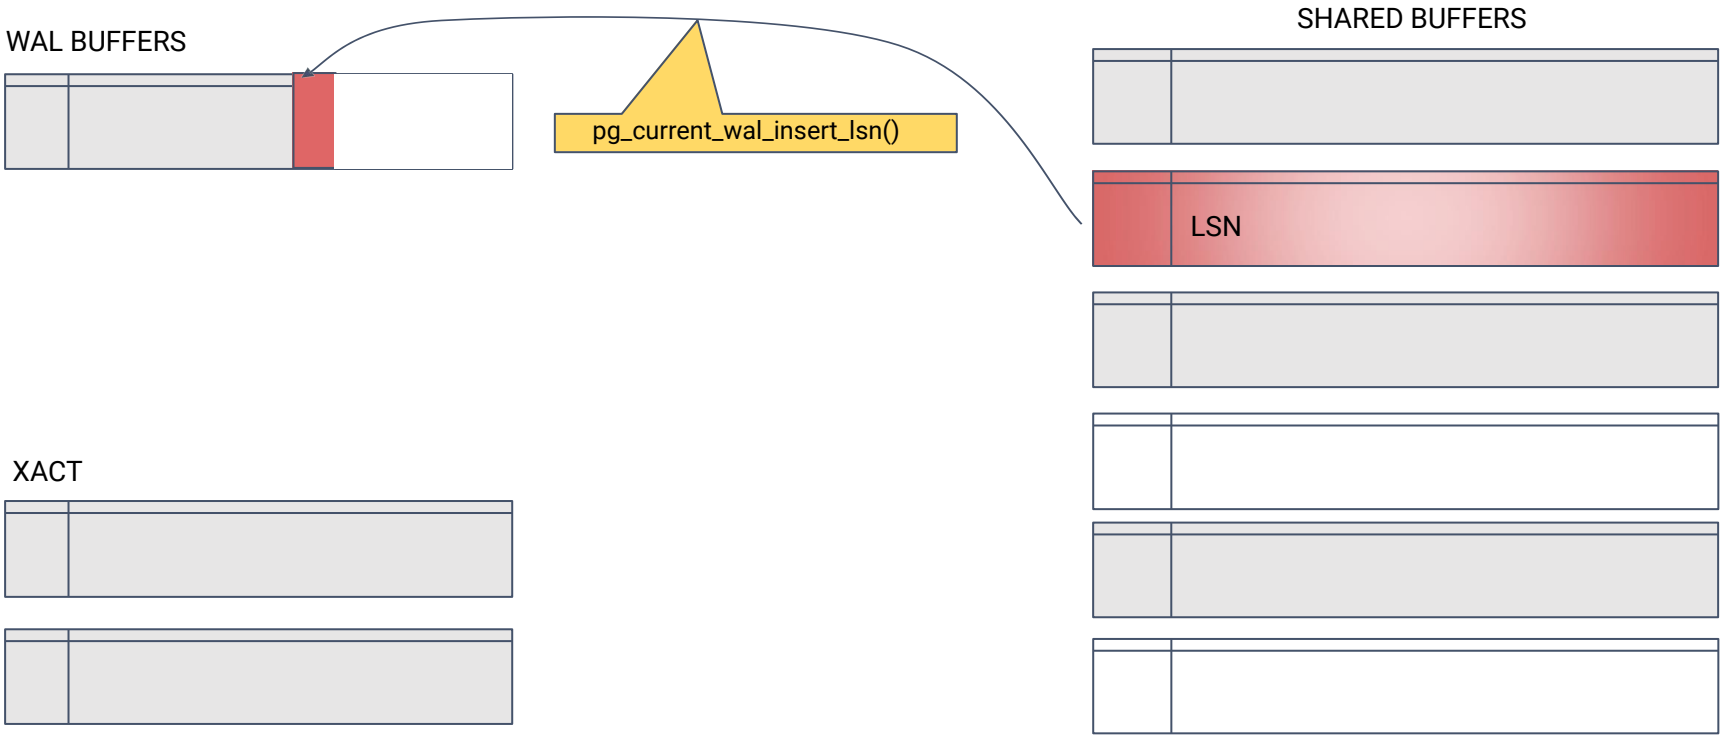

WAL. Механизм упреждающей записи

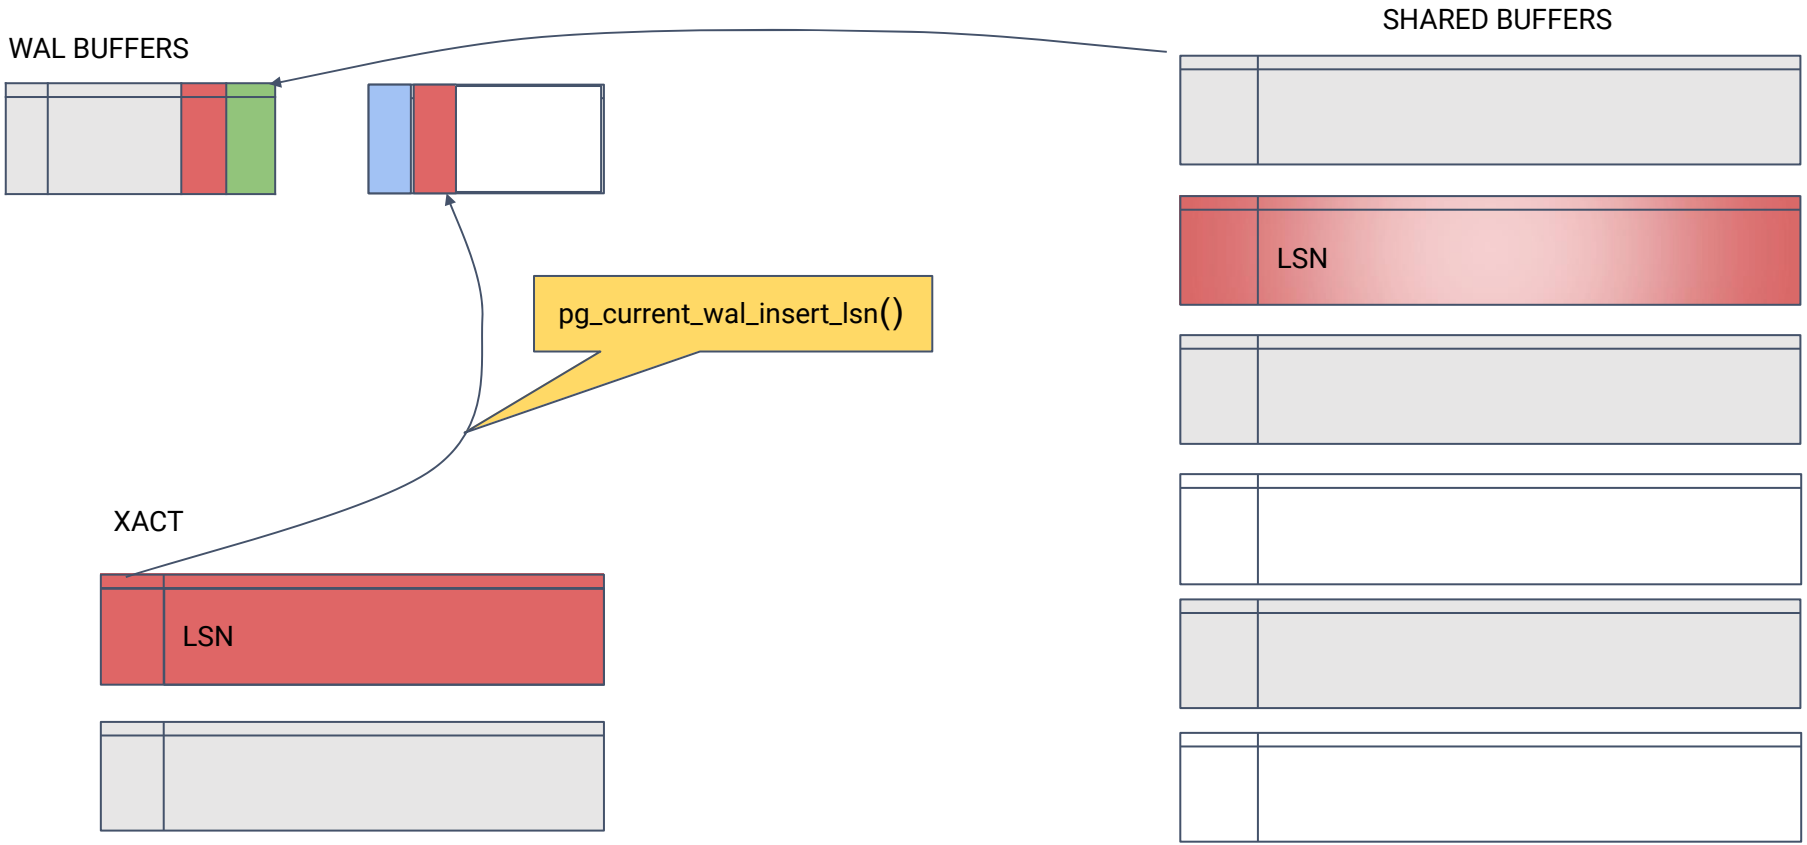

WAL. Механизм упреждающей записи

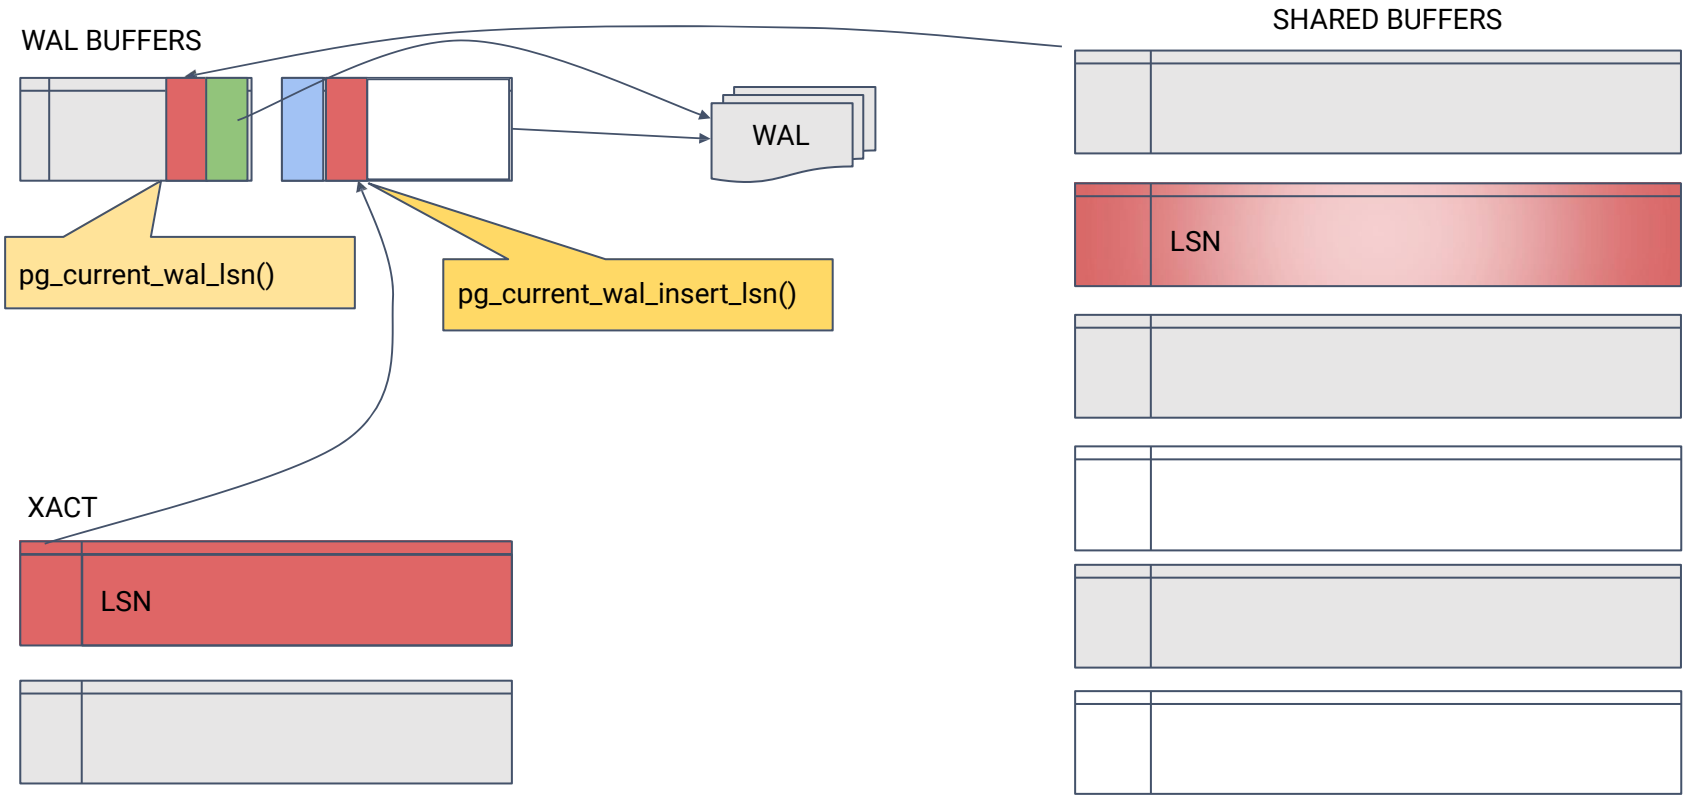

WAL. Механизм упреждающей записи

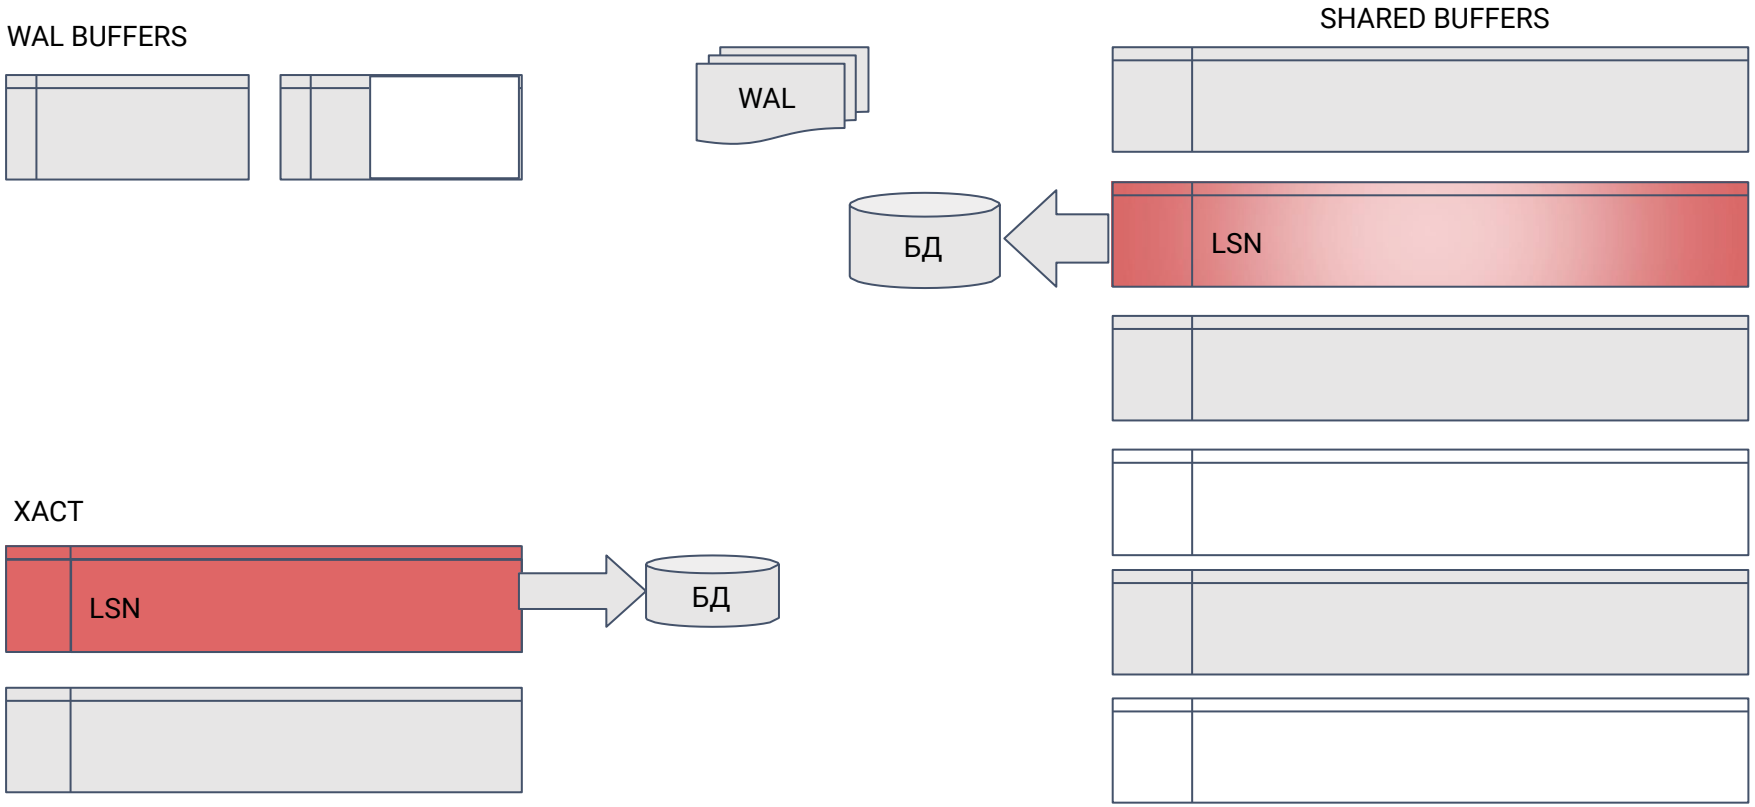

WAL. Восстановление

При старте сервера после сбоя

(состояние кластера в pg_control отличается от «shut down»):

- для каждой журнальной записи:
  - определить страницу, к которой относится эта запись
  - применить запись, если ее LSN больше, чем LSN страницы
- перезаписать нежурналируемые таблицы init-файлами

Вопросы?

Контрольная точка

Контрольная точка

Зачем она нужна? Можно же с самого начала накатить все wal?

Контрольная точка

Зачем она нужна? Можно же с самого начала накатить все wal?

- очень большой объем информации хранить
- большое время восстановления
- сколько может страница измененная лежать в буферном кэше?

Контрольная точка

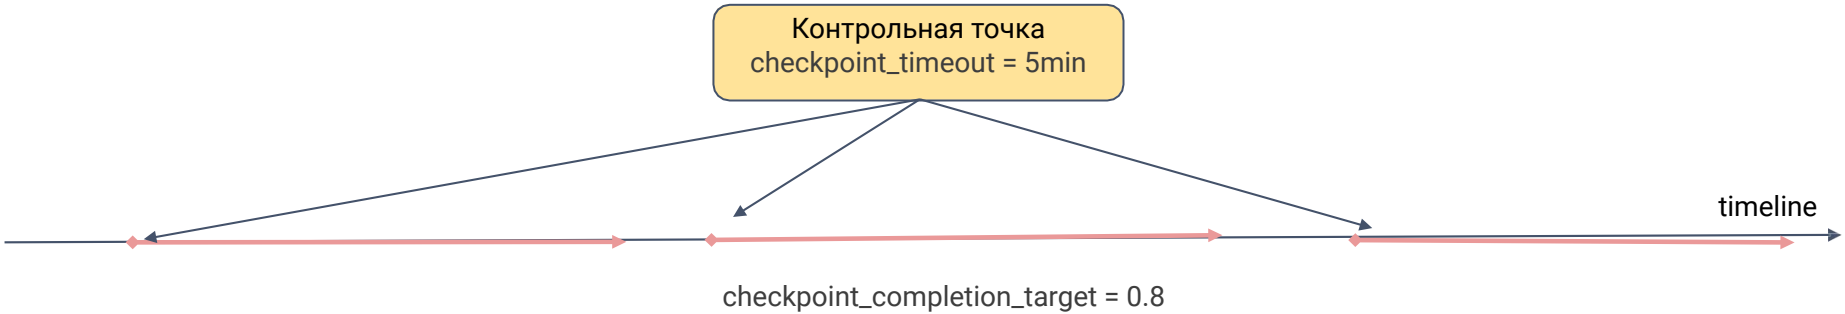

Контрольная точка

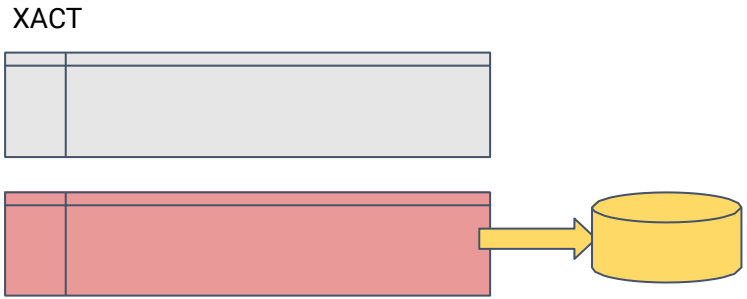

- сначала сбрасываются буферы XACT
- помечаются грязные буферы

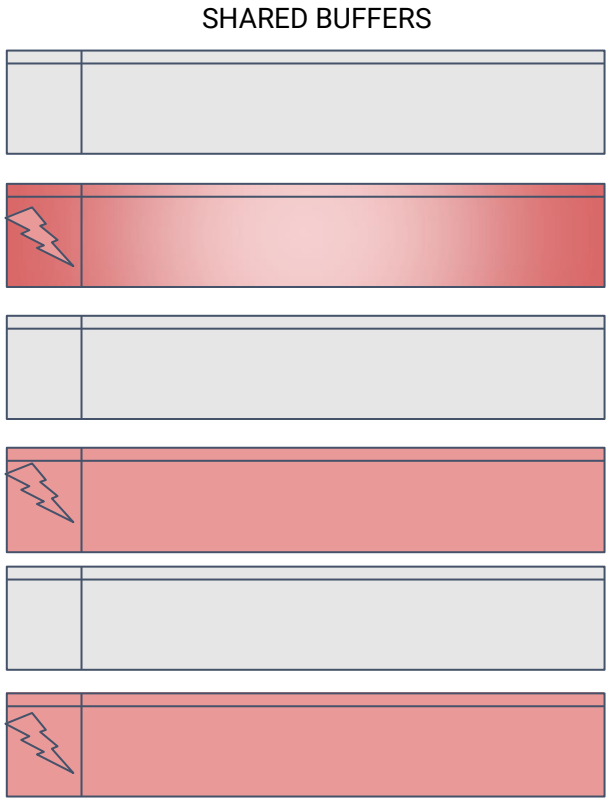

Контрольная точка

- зная значение параметра checkpoint_completion_target = 0.5 и количество блоков, которые нужно записать мы рассчитываем равномерную запись
- помеченные страницы постепенно записываются
- пометка убирается из заголовка буфера

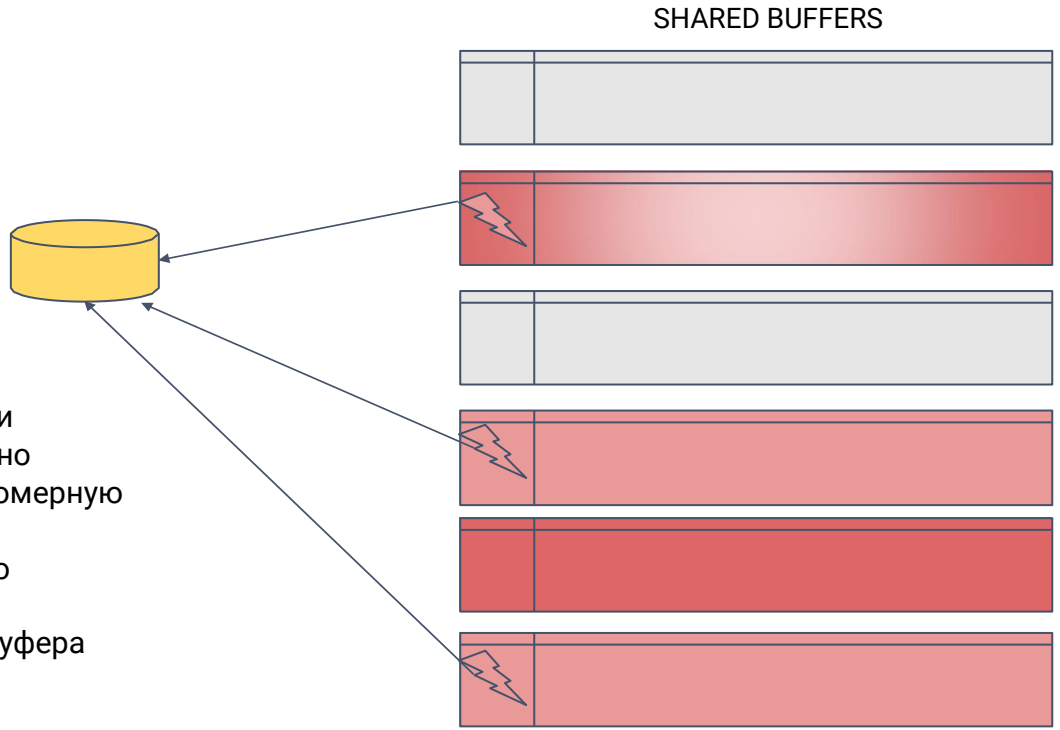

Контрольная точка

WAL

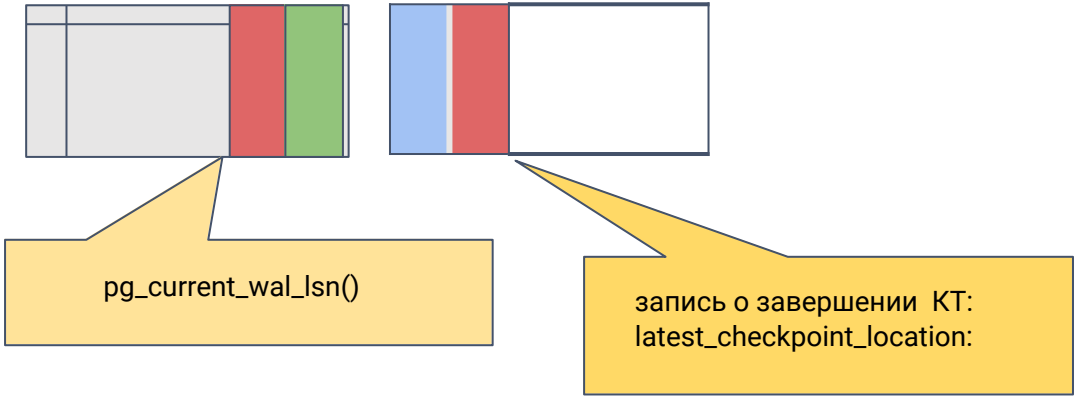

- 1. в журнале создается запись о завершении контрольной точки с указанием момента ее начала
- 1. в файл $PGDATA/global/pg_control записывается LSN контрольной точки
  - ...
  - Latest checkpoint location: 0/12B35EBB
  - …

Контрольная точка

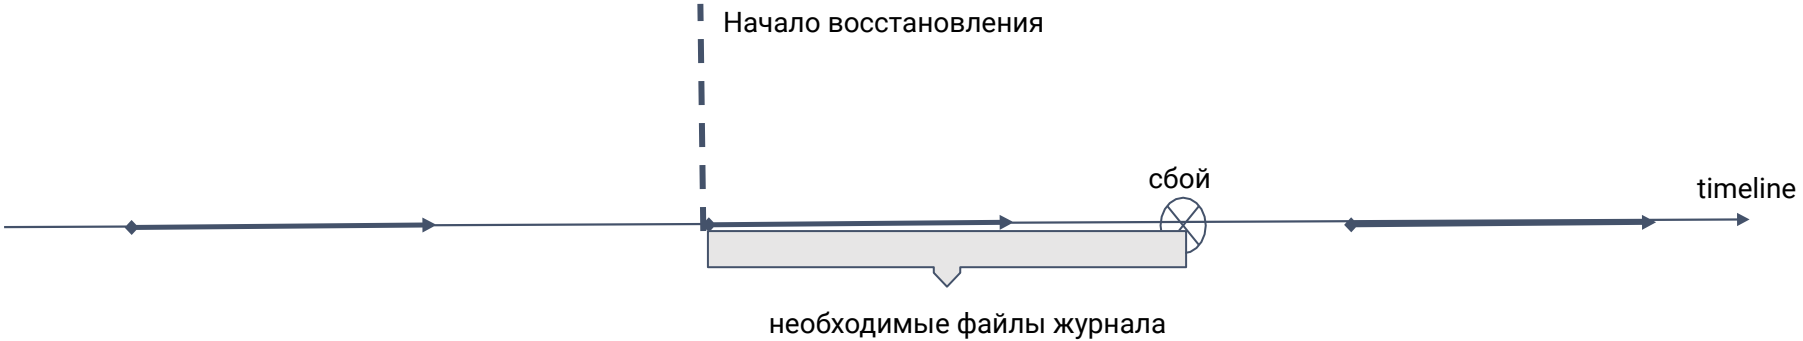

Контрольная точка

С какой точки произойдет восстановление и за какой период нужны будут wal файлы?

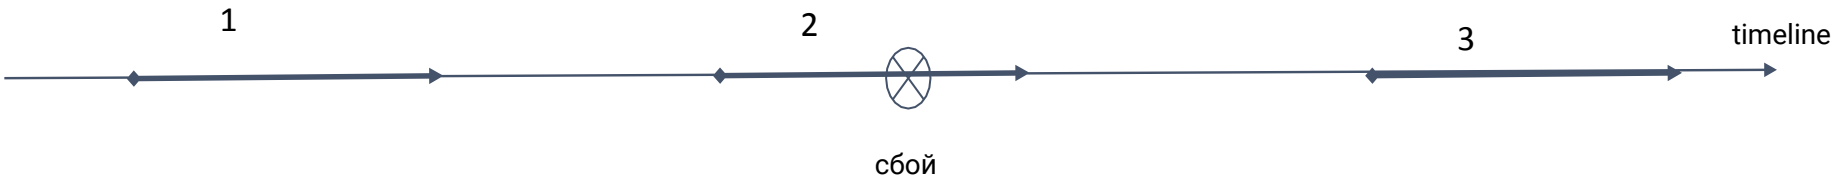

Контрольная точка

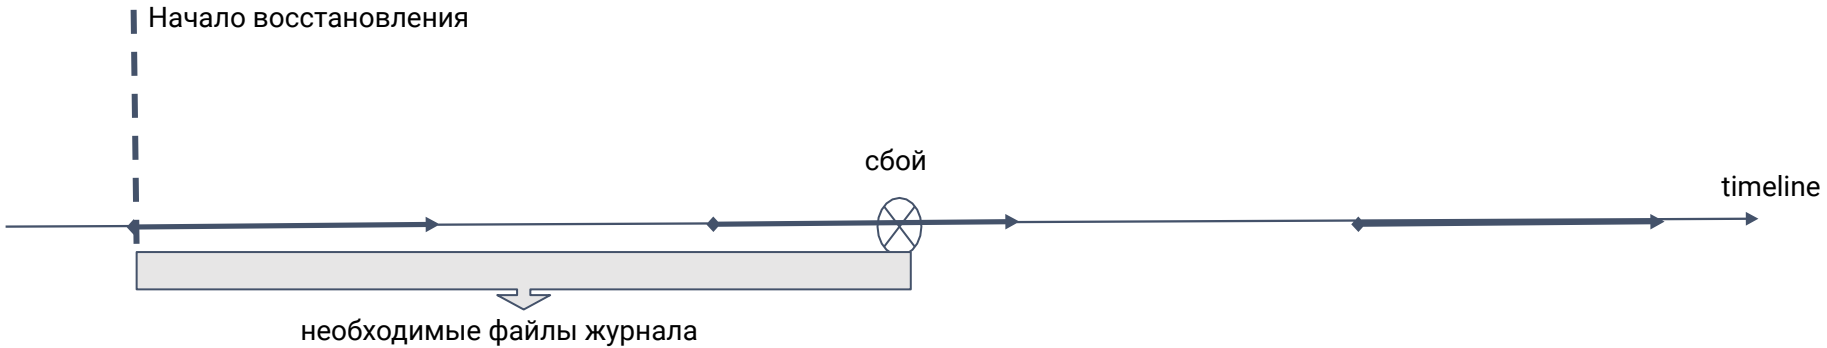

Контрольная точка

При старте сервера после сбоя

- Найти LSN0 начала последней завершенной контрольной точки;
- Применить каждую запись журнала, начиная с LSN0, если LSN записи больше, чем LSN страницы;
- Перезаписать нежурналируемые таблицы init-файлами;
- Выполнить контрольную точку.

Контрольная точка

- **Настройка частоты срабатывания:**
  - checkpoint_timeout = 5min
  - max_wal_size = 1GB
- **Сервер хранит журнальные файлы необходимые для восстановления:**
  - (2 (1 с 12 версии) + checkpoint_completion_target) * max_wal_size
  - еще не прочитанные через слоты репликации
  - еще не записанные в архив, если настроена непрерывная архивация
  - не превышающие по объему минимальной отметки
- **Настройки**
  - max_wal_size = 1GB
  - min_wal_size = 100MB
  - wal_keep_segments = 0

Контрольная точка. Процесс фоновой записи

В какой-то момент все свободные блоки заканчиваются. Что делать дальше?

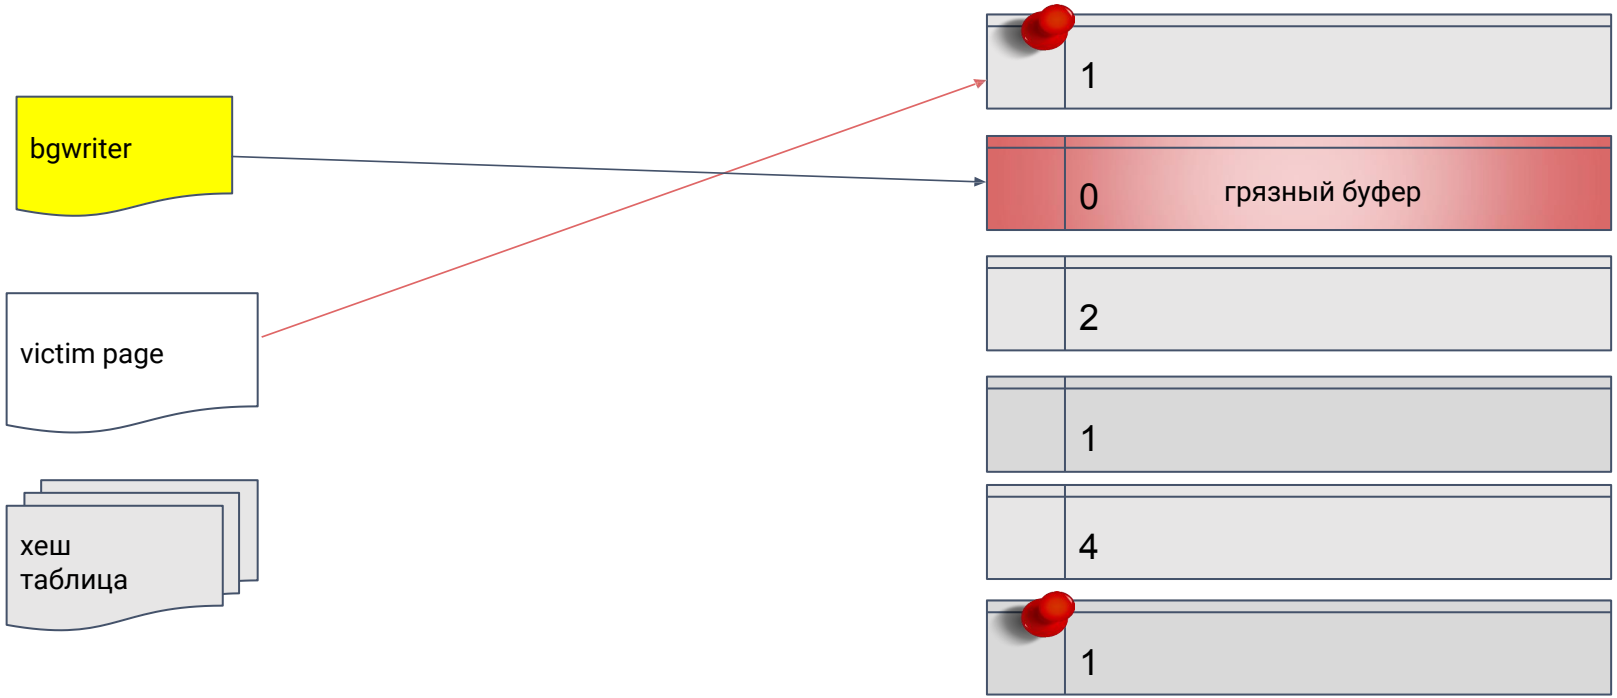

Контрольная точка

- **Настройки**
  - bgwriter_delay = 200ms
  - bgwriter_lru_maxpages = 100
  - bgwriter_lru_multiplier = 2.0
- **Алгоритм**
  - уснуть на bgwriter_delay
  - если в среднем за цикл запрашивается N буферов, то записать N * bgwriter_lru_multiplier ≤ bgwriter_lru_maxpages грязных буферов

Контрольная точка. Практика

Вопросы?

Настройка журнала

Уровни журнала

- **Minimal**
  - восстановление после сбоя
- **Replica**
  - восстановление из резервной копии, репликация
  - + операции массовой обработки данных, блокировки
- **Logical**
  - логическая репликация
  - + информация для логического декодирования
- **Настройка**
  - wal_level = replica

Настройка записи на диск

Синхронизация с диском

- данные должны дойти до энергонезависимого хранилища через многочисленные кэши
- СУБД сообщает операционной системе способом, указанным в wal_sync_method надо учитывать аппаратное кэширование

Настройки

- fsync = on;
- show fsync;
- show wal_sync_method;
- утилита pg_test_fsync помогает выбрать оптимальный способ

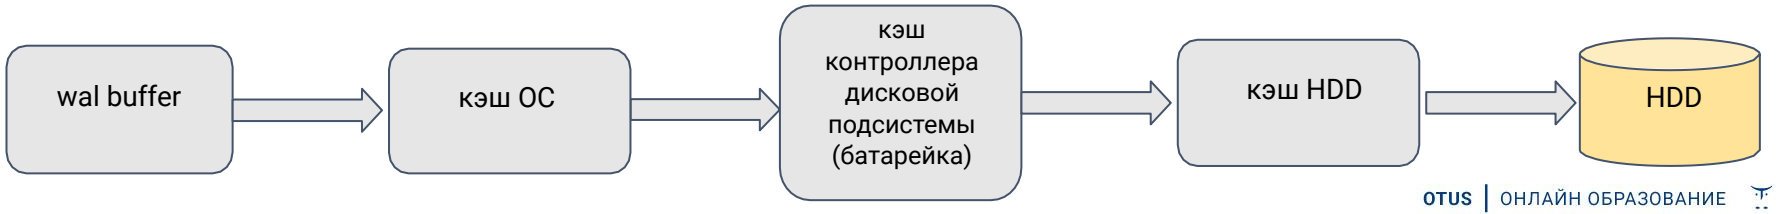

Повреждение данных

- **Контрольные суммы журнальных записей**
  - включены всегда, CRC-32
- **Контрольные суммы страниц (накладные расходы)**
  - По умолчанию отключены. До 12 версии можно включить только при инициализации кластера.
  - pg_createcluster --data-checksums
- **Настройки**
  - show data_checksums;
  - ignore_checksum_failure = off;
  - wal_log_hints = off (записывает все содержимое каждой страницы при измениях даже инф.бит, неявно on при контрольных суммах страниц);
  - wal_compression = off;

Характер нагрузки

Постоянный поток записи

- характер нагрузки отличается от остальной системы
- последовательная запись, отсутствие случайного доступа
- при высокой нагрузке — размещение на отдельных физических дисках (символьная ссылка из $PGDATA/pg_wal)

Редкое чтение

- при восстановлении
- при работе процессов walsender, если реплика не успевает быстро получать записи

Режим записи

- синхронный режим
- асинхронный режим

Режим синхронной записи

- **Алгоритм**
  - при фиксации изменений сбрасывает накопившиеся записи, включая
  - запись о фиксации
  - ждет commit_delay, если активно не менее commit_siblings транзакций

- **Характеристики**
  - гарантируется долговечность
  - увеличивается время отклика

- **Настройки**
  - synchronous_commit = on
  - commit_delay = 0
  - commit_siblings = 5

Режим асинхронной записи

- **Алгоритм**
  - циклы записи через wal_writer_delay
  - записывает только целиком заполненные страницы
  - но если новых полных страниц нет, то записывает последнюю до конца

- **Характеристики**
  - гарантируется согласованность, но не долговечность
  - зафиксированные изменения могут пропасть (3 × wal_writer_delay)
  - уменьшается время отклика

- **Настройки**
  - synchronous_commit = off (можно изменять на уровне транзакции)
  - wal_writer_delay = 200ms

Рефлексия

Вопросы?

- Кто что запомнил за сегодня?
- Сколько контрольных точек рекомендовано хранить для гарантированного восстановления?
- Как вам баланс между теорией и практикой?

Домашнее задание

ДЗ

1. Настройте выполнение контрольной точки раз в 30 секунд.
2. 10 минут с помощью утилиты pgbench подавайте нагрузку.
3. Измерьте, какой объем журнальных файлов был сгенерирован за это время. Оцените, какой объем приходится в среднем на одну контрольную точку.
4. Проверьте данные статистики: все ли контрольные точки выполнялись точно по расписанию. Почему так произошло?
5. Сравните tps в синхронном/асинхронном режиме утилитой pgbench. Объясните полученный результат.
6. Создайте новый кластер с включенной контрольной суммой страниц. Создайте таблицу. Вставьте несколько значений. Выключите кластер. Измените пару байт в таблице. Включите кластер и сделайте выборку из таблицы. Что и почему произошло? как проигнорировать ошибку и продолжить работу?

Заполните, пожалуйста, опрос о занятии по ссылке в чате

Спасибо за внимание!

Приходите на следующие вебинары

Ведущий разработчик PostgreSQL/Greenplum в Сбере

Специалист в области разработки и проектировании витрин данных в PostgreSQL/Greenplum, а также в области разработки хранимых процедур в таких СУБД как PostgreSQL/Greenplum, Oracle, MS SQL Server.